

ShinobuChat 三级意图识别方案

来源文件：shinobuchat-three-level-intent-scheme.md

结合当前项目实现、历史 IntentRecognizer 设计和现有 RouteMode / SkillRegistry / AgentOrchestrator 结构整理。目标：让 ShinobuChat 能区分“陪我聊”“帮我做事”“需要拒绝或降级”的输入，并把识别结果落实到前后端行为上。

1. 总体设计

ShinobuChat 的意图识别采用三级方案：

层级	名称	主要作用	当前项目对应
第一级	正则/关键词快速分类	低成本识别高确定性意图，决定是否命中技能或安全规则	历史 IntentRecognizer、当前 Skill Registry.match()、受限工具规则
第二级	AI 意图识别提示词	对模糊输入进行语义判断，给出 route、intent、emotion、action plan	当前 RouteMode.AUTO 的升级方向，接入 AgentService.build_messages()
第三级	安全检查与执行门控	在真正调用工具、保存记忆、访问外部资源前做权限和风险判断	get_current_user()、Pydantic 限制、shell_command 限制、工具白名单

这三级不是互相替代，而是逐步收窄：

```
flowchart LR
    A["用户输入"] --> B["第一级：关键词/正则"]
    B --> C{"高确定性?"}
    C -- 是 --> D["命中 route / skill / safety"]
    C -- 否 --> E["第二级：AI 意图识别"]
    E --> F["结构化意图结果"]
    F --> G["第三级：安全检查"]
    G --> H
    H --> I{"允许执行?"}
    I -- 是 --> J["聊天 / Agent / 工具 / 语音 / Live2D"]
    I -- 否 --> K["拒绝 / 降级 / 请求确认"]
```

2. 第一级：正则匹配词库分类、回复及实现效果

第一级用于识别最明确、最常见、风险较低的输入。它速度快、可解释，适合放在后端消息入口或 SkillRegistry 前后。

2.1 分类词库

分类	典型关键词 / 正则	route 建议	命中后回复策略	实现效果
陪伴聊天	陪我聊、有点累、难过、开心、吐槽、想你	chat	先共情，再给 1-3 句轻量回应；不强行拆任务。	保持桌宠陪伴感，避免把情绪表达误判成任务。
待办整理	待办、todo、要做、任务、别忘了、清单	agent	确认要整理的事项，必要时生成列表或调用待办技能。	将闲聊输入转为可执行条目。

分类	典型关键词 / 正则	route 建议	命中后回复策略	实现效果
提醒/时间	提醒、明天、后天、周[一二三四五六日]、\d{1,2}\s*[点:]、ddl	agent	抽取时间、事件、优先级；不清楚时追问。	支持轻量日程/提醒入口。
记忆写入	记住、记一下、保存、记录、以后我、我的偏好	agent	先复述将保存的内容，敏感内容需确认。	为长期陪伴和个性化打基础。
灵感整理	灵感、点子、想法、脑洞、帮我整理、归类	agent	提取主题、标签、下一步行动。	把零散想法变成可回看的结构。
网页/资料查询	搜索、查一下、网页、资料、对比、总结这个链接	agent	启用网页搜索/抓取技能，返回摘要和来源。	让聊天自然扩展到资料检索。
读屏/OCR	截图、截屏、读屏、OCR、看图	agent	请求上传图片或说明当前无法读取屏幕。	避免假装看到了未提供的画面。
语音交互	语音、朗读、读出来、麦克风、听我说	auto	根据前端状态触发 ASR/TTS 或提示开启权限。	将文本意图连接到语音链路。
角色设置	角色、语气、人设、prompt、Live2D、模型、背景	agent	引导到角色卡或设置面板，保存前确认。	让用户能调整桌宠人格和外观。
明确闲聊禁用工具	别查、不用做、只聊天、别调用工具	chat	尊重用户意愿，只作自然语言回应。	防止过度 Agent 化。
高风险/违规	删除数据库、泄露 token、绕过登录、执行命令、rm -rf、恶意脚本	reject / confirm	拒绝、解释原因，或请求明确授权和安全替代方案。	将危险输入挡在工具调用前。

2.2 推荐实现方式

```
INTENT_RULES = [  
  {  
    "name": "companion_chat",  
    "route": "chat",  
    "keywords": ["陪我聊", "有点累", "难过", "开心", "吐槽"],  
    "reply_style": "empathetic_short",  
  },  
  {  
    "name": "todo_summary",  
    "route": "agent",  
    "keywords": ["待办", "todo", "任务", "要做", "别忘了"],  
    "skill": "todo_summary",  
  },  
  {  
    "name": "set_reminder",  
    "route": "agent",  
    "patterns": [r"提醒", r"明天|后天|今天", r"周[一二三四五六日]", r"\d{1,2}\s*[点: ]"],  
    "requires_confirmation": True,  
  },  
]
```

实现效果：

- 输入“今天有点累，陪我聊会儿” -> chat，只做陪伴回应。
- 输入“帮我整理一下今天的待办” -> agent，命中 todo_summary。
- 输入“明天下午三点提醒我交作业” -> agent，抽取提醒时间并要求确认。
- 输入“只聊天，别调用工具” -> 强制 chat，跳过技能匹配。

3. 第二级：AI 意图识别提示词模板及实现效果

当第一级无法判断，或输入同时包含情绪、任务和限制条件时，交给 AI 做结构化识别。

3.1 提示词模板

你是 ShinobuChat 的意图识别器。你的任务不是回复用户，而是把用户输入分类成结构化 JSON。

- 项目背景：
- ShinobuChat 是 Live2D 桌宠聊天伙伴，支持 chat / agent / auto 三种路由。
 - chat 用于陪伴、情绪回应、自然聊天。
 - agent 用于待办、提醒、资料查询、读屏、灵感整理、角色设置等可执行任务。
 - 系统支持技能：weather、todo_summary、evening_review、inspiration_organizer、screen_reader、web_search_aggregator。
 - 回复可能驱动 Live2D 情绪：happy、sad、angry、surprised、thinking、neutral。

请只输出 JSON，不要输出解释。

```
JSON schema:
{
  "route": "chat | agent | ask_clarification | reject",
  "primary_intent": "companion_chat | todo | reminder | memory | search | screen_reader | voice | character_setting | weather | unknown | unsafe",
  "skills": ["skill_name"],
  "confidence": 0.0,
  "emotion": "happy | sad | angry | surprised | thinking | neutral",
  "requires_confirmation": true,
  "safety_risk": "none | privacy | command | external_network | data_write | auth | harmful",
  "extracted_slots": {
    "title": "",
    "datetime_text": "",
    "query": "",
    "url": "",
    "preference": ""
  },
  "user_facing_summary": "用一句中文说明你理解到的用户意图"
}
```

- 判定规则：
1. 用户表达情绪、陪伴、闲聊，且没有明确任务时，route=chat。
 2. 用户要求查找、整理、保存、提醒、读取屏幕、修改设置时，route=agent。
 3. 信息不足且执行会产生副作用时，route=ask_clarification。
 4. 涉及绕过认证、泄露密钥、执行危险命令、删除数据、攻击他人时，route=reject。
 5. 如果用户明确说“只聊天/别调用工具”，route=chat。
 6. 如果用户要求保存记忆、创建提醒、调用外部网页或执行命令，requires_confirmation=true。

用户输入：
{{USER_INPUT}}

3.2 示例效果

用户输入	AI 识别结果摘要	实现效果
“今天好累，陪我说两句就好。”	route=chat, primary_intent=companion_chat, emotion=sad	走普通聊天；Live2D 可切到安静/关心表情。
“帮我把今天的想法整理成三个待办。”	route=agent, primary_intent=todo, skills=["todo_summary"]	加载待办总结技能，返回结构化清单。

用户输入	AI 识别结果摘要	实现效果
“ 查一下明天香港会不会下雨。 ”	route=agent, primary_intent=weather, skills=["weather"]	调用天气技能或外部查询，输出简短天气建议。
“ 记住我不喜欢太频繁的提醒。 ”	route=agent, primary_intent=memory, requires_confirmation=true	先复述将保存的偏好，确认后写入记忆。
“ 把这个网页总结一下：https://example.com ”	route=agent, primary_intent=search, safety_risk=external_network	通过网页抓取工具读取页面，摘要并标注来源。
“ 帮我绕过登录拿到别人的 token。 ”	route=reject, primary_intent=unsafe, safety_risk=auth	拒绝请求，给出安全替代建议。

3.3 与当前项目的衔接

当前代码已经具备承接这套方案的基础：

- MessageCreate.route_mode 已支持 auto/chat/agent。
- MessageService 已根据 route_mode 分流聊天与 Agent。
- SkillRegistry.match() 已能从 skills/*/SKILL.md 匹配技能。
- AgentService.build_messages() 已能注入技能目录和已激活技能。
- AgentOrchestrator 已支持工具调用与 progress 事件。

建议下一步把 AI 意图识别结果作为 auto 模式的前置步骤：

```
route_mode=chat -> 直接普通聊天
route_mode=agent -> 直接 Agent 流程
route_mode=auto -> 正则匹配 -> AI 意图识别 -> 安全检查 -> chat 或 agent
```

4. 第三级：项目安全检查规则

ShinobuChat 是一个会调用工具、访问网页、保存会话、处理语音和可能写入记忆的桌面 AI 应用，因此安全检查要围绕“身份、数据、工具、外部请求、语音文件、模型输出”六个方面展开。

4.1 身份与权限

规则	当前实现 / 建议
所有消息接口必须绑定当前用户	当前 messages.py 通过 get_current_user() 从 Bearer token 获取用户，并覆盖 payload.user_id。
token 无效或过期必须拒绝	decode_access_token() 捕获过期、JWT 错误、UUID 错误并抛出 UnauthorizedError。
前端不得决定最终用户身份	后端应始终以 token 中用户为准，不信任前端传入 user_id。
会话与消息必须按用户隔离	ConversationService.get_for_user()、消息列表接口需要持续保持用户过滤。

4.2 输入与内容边界

规则	当前实现 / 建议
单条消息长度限制	MessageCreate.content 设置 max_length=4000。

规则	当前实现 / 建议
语音文件大小限制	应使用配置中的上传大小限制，拒绝超大文件。
空输入拒绝	MessageCreate.content 设置 min_length=1。
角色 prompt 注入风险	保存角色卡前应过滤“忽略系统规则”“泄露密钥”等高风险片段，或标记为仅影响角色语气。
AI 情绪标签白名单	仅接受 happy/sad/angry/surprised/thinking/neutral，其他值归一到 neutral。

4.3 工具调用安全

工具/能力	安全规则	
shell_command	只允许 curl/curl.exe；拒绝 `	、&、;、>、<、反引号、\$()；限制超时时间；截断输出。
fetch_web_page	只用于用户明确要求或技能需要；限制响应大小和超时；返回摘要而不是盲目执行网页内容。	
activate_skill	只能激活本地已安装技能；未知技能返回错误。	
conversation_digest	只读取当前会话上下文，不能跨用户读取。	
记忆/待办写入	需要确认，尤其是长期记忆、提醒、偏好保存。	

4.4 外部网络与隐私

规则	说明
外部查询必须可解释	当访问网页、天气或搜索服务时，回复中说明信息来自外部查询。
不自动上传隐私内容	截图、语音、聊天历史、记忆内容不得在无明显意图时发送给外部服务。
敏感信息不进入长期记忆	密码、token、身份证号、银行卡、私密健康信息默认不保存。
用户可撤销	记忆和提醒类写入应提供删除/撤销入口。

4.5 语音与媒体安全

规则	说明
ASR 文件类型检查	只接受常见音频 MIME 类型，拒绝伪装文件。
ASR/TTS 超时	避免外部语音服务阻塞 SSE。
TTS 文本清洗	使用 clean_tts_text() 去掉 Markdown、链接、代码等不适合朗读的内容。
分句播放	使用 sentence_splitter 控制句子长度，避免一次性播报过长文本。
音频失败降级	TTS 失败时仍返回文本，不让语音服务破坏聊天主流程。

4.6 模型输出安全

规则	说明
情绪标签必须解析后移除	存库和展示时使用去标签文本，避免污染用户可见内容。
Agent 进度与最终回复分离	progress 用于执行状态，最终回复仍由 done 或文本消息承载。

规则	说明
工具结果不能原样倾倒	系统 prompt 要求把工具结果解释为自然语言，不直接输出长日志。
空回复视为上游错误	当前 MessageService 对空 AI 回复抛出 UpstreamServiceError。

5. 三级方案落地后的完整效果

用户输入“明天下午三点提醒我交作业，别太啰嗦”时：

- 1 第一级正则命中“明天”“三点”“提醒”，初判为 reminder。
- 2 第二级 AI 补齐语义：提醒事项是“交作业”，回复风格是“简短”，需要确认。
- 3 第三级安全检查确认这是数据写入操作，不直接静默创建提醒。
- 4 前端收到 progress：正在识别提醒。
- 5 Shinobu 回复：“我理解是明天下午 3 点提醒你交作业。确认后我就记下。”
- 6 用户确认后才写入待办/提醒。

用户输入“今天压力好大，别分析，陪我待一会儿”时：

- 1 第一级命中情绪与“别分析”。
- 2 直接走 chat，跳过 Agent。
- 3 AI 输出 [sad] 开头的安静陪伴回复。
- 4 前端解析情绪，Live2D 切换到安静/关心动作。
- 5 不创建任务、不写记忆、不调用工具。

用户输入“用命令帮我删掉数据库”时：

- 1 第一级命中危险操作。
- 2 第二级可选复核为 unsafe。
- 3 第三级工具门控拒绝执行；shell_command 本身也不允许非 curl 命令。
- 4 回复说明不能执行破坏性操作，并建议提供备份、迁移或安全清理方案。

6. 总结

ShinobuChat 的三级意图识别方案，本质上是在保护项目最重要的产品边界：

- 用户需要陪伴时，不要把情绪误当任务。
- 用户需要行动时，不要只给空泛建议。
- 用户触及隐私、外部网络、长期记忆或命令执行时，不要越权替用户做决定。

这套方案与当前成品高度匹配：正则层延续历史 IntentRecognizer 的确定性，AI 层补足 auto 模式的语义判断，安全层则利用现有 JWT、Pydantic、工具白名单和 SSE 降级机制，把“可爱的桌宠”变成一个真正可长期使用的 AI-Native 应用。